

# 用于肺结节检测和分类的两阶段深度学习方法

贾 锋, 薛潺涓, 王 欣

(吉林大学 计算机科学与技术学院, 长春 130012)

**摘要:** 针对肺部 CT 数据具有空间信息的特点, 提出一种基于深度学习的两阶段方法, 即使使用两个 3D 卷积网络有效学习结节特征, 对 CT 图像中的肺结节进行检测和分类. 该方法的检测器部分采用基于 U-Net 的编码器-解码器结构的 3D 语义分割模型, 以预测结节的位置、大小和语义掩码; 分类器部分采用 3D 双路径网络, 用于特征的汇总和收缩, 并给出分类结果. 为充分利用原始数据中的特征信息, 将检测器的结果应用于对原始数据进行采样和掩码操作, 并通过空间金字塔池化层获得一致的输入尺度. 在公开数据集上的实验结果表明, 该深度学习方法对 CT 图像肺结节的检测和分类具有良好的性能.

**关键词:** 肺结节; 检测; 分类; 深度学习

**中图分类号:** TP391 **文献标志码:** A **文章编号:** 1671-5489(2020)02-0329-08

## Two-Stage Deep Learning Method for Detection and Classification of Pulmonary Nodules

JIA Feng, XUE Chanjuan, WANG Xin

(College of Computer Science and Technology, Jilin University, Changchun 130012, China)

**Abstract:** Aiming at the characteristics of lung CT data with spatial information, we proposed a two-stage method based on deep learning for the detection and classification of pulmonary nodules in CT images. Two 3D convolution networks were used to effectively learn nodule features. For the detector part of the method, a 3D semantic segmentation model was designed for nodule detection with a U-Net-like encoder-decoder structure to predict the location, size and semantic mask of the nodules. For the classifier part, a 3D dual path network was used to summarize and contract features, and the classification results were given. In order to fully utilize the feature in the original data, the results of the detector were used to sample and mask the original data, and a spatial pyramid pooling layer was added before the classifier to obtain a consistent input scale. The experimental results on public datasets show that the proposed deep learning approach has good performance in the detection and classification of pulmonary nodules in CT images.

**Keywords:** pulmonary nodules; detection; classification; deep learning

在肺癌早期筛查中, 肺部计算机 X 射线断层扫描(computed X-ray tomography, CT)图像上的肺结节可为医生提供诊断依据<sup>[1]</sup>. 而计算机辅助诊断系统对肺癌的早期诊断有重要意义, 能准确高效地

收稿日期: 2019-08-22.

第一作者简介: 贾 锋(1995—), 男, 汉族, 硕士研究生, 从事图像处理与深度学习的研究, E-mail: jiafeng5513@outlook.com.  
通信作者简介: 王 欣(1975—), 女, 汉族, 博士, 副教授, 从事计算机图形学、图像处理与虚拟现实的研究, E-mail: w\_x@jlu.edu.cn.

基金项目: 吉林省科技发展计划项目(批准号: 201603054YY; 20170414006GH).

筛查大量 CT 图像,并有效减少医生由于疲劳而导致的误诊.近年来,由于深度学习在图像处理中取得的优异成绩<sup>[2-7]</sup>,将深度学习算法应用在医学图像处理中被广泛关注<sup>[8-11]</sup>.例如:Roth 等<sup>[12]</sup>采用卷积网络进行肺结节的检测;Ciompi 等<sup>[13]</sup>采用深度学习方法进行肺裂隙周围结节的分类,为提高准确率,同时采用了轴向面、冠状面和矢状面的 CT 视图;Kumar 等<sup>[14]</sup>使用自编码器的方法进行肺结节的分类.上述研究尽管都取得了较好的效果,但都只采用二维卷积进行特征提取,不仅未使用结节的周长、尺寸等固有特征,还忽略了肺部 CT 实际上是三维数据的特性.针对该问题,Kim 等<sup>[15]</sup>提出了使用深度学习寻找 CT 影像中潜在特征的方法;Zhu 等<sup>[16]</sup>提出了使用三维卷积的肺结节检测和分类方法.

使用三维数据对提高肺结节检测和分类的准确率有重要意义,但提高了数据处理的压力,且肺结节的检测和分类任务所需的模型容量较大,进一步增加了基于深度学习,尤其是使用三维卷积方法所需模型的规模和内存.常见的解决方案是采用大窗口、小步长的密集裁剪方法降低网络的单次数据吞吐量<sup>[11,16]</sup>,但盲目地进行密集裁剪会导致样本量的激增,降低训练效率,且容易破坏结节特征.基于此,本文提出一种基于语义分割和空间金字塔池化<sup>[17]</sup>的多尺度深度学习方法,用于 CT 影像中肺结节的检测和分类.实验结果表明,本文提出的模型在 LUNA16<sup>[18]</sup>公开数据集上表现出了对肺结节检测和分类的良好性能,同时避免了对数据的盲目裁剪,提高了特征的利用率和训练效率.

## 1 目标检测

从 CT 图像中确定肺结节的位置,属于图形学中的“目标检测”任务.Faster-RCNN<sup>[19]</sup>是具有代表性的基于深度学习的目标检测方法.该方法首先使用一个卷积网络进行特征提取,卷积网络可以是 VGG-16<sup>[20]</sup>或 ResNet101<sup>[21]</sup>等合适的模型,再使用区域建议网络(region proposal networks, RPN)进行候选区域提名,最后使用 ROI Pooling 综合卷积网络提取特征和候选区域,并统一多尺度输入,提供给分类后端进行分类和输出.Faster-RCNN 的候选区域提名采用“anchor+偏移量”的描述方法,其中 anchor 表示给定的一系列标识位置的矩形框,通过对这些矩形框施加一个网络预测产生的偏移量框定目标区域,避免了选择性搜索<sup>[22]</sup>等方法的大量时间开销.本文借鉴这种方法,针对肺结节检测任务的特点,在肺结节检测中采用尺度为 5,10,20 的三种 anchor 以及  $x, y, z, d$  四个偏移量描述一个候选结节的位置和直径.

## 2 语义分割

语义分割任务是对输入图像中每个像素进行分类的过程,与其他图像任务相比,语义分割最显著的特征是输出结果为一张图片,每个像素值表示输入图片对应位置的分类结果.基于深度学习的语义分割有全卷积网络(fully convolutional network, FCN)<sup>[23]</sup>、Tiramisu<sup>[24]</sup>和 U-Net<sup>[25]</sup>等方法.考虑到 U-Net 的网络结构有较大设计空间,且可广泛应用于医学图像的处理,因此本文使用基于 U-Net 的三维卷积模型进行肺结节的检测.语义分割的优势为除了能给出定位和分类结果外,还能提供对输入场景的语义分割结果.本文使用语义分割结果对分类器的输出进行预处理,用以屏蔽非结节区域并突出候选结节区域,以提高分类的灵敏度.

## 3 算法设计

### 3.1 预处理

对肺部 CT 图像进行预处理的目的是主要有两个:首先,肺部周围的一些结构,如血管或支气管的横断面在结构上相似,这些肺部外的结构不但会增加无关数据量,还会对检测结构产生干扰,因此需将肺部以外的区域去除;其次,CT 图像具有较大的位深度,使得其数值范围很大,不利于神经网络的收敛,因此需要对图像进行归一化.

CT 值反映物质的密度,肺部的 CT 值为  $-450 \sim 600$  HU.本文基于文献<sup>[11]</sup>的工作对肺部 CT 图像进行了预处理,取  $-400$  HU 为窗位,1 500 为窗宽,该状态下的原始肺部图像如图 1(A)所示.然后

对图像依次进行二值化、清除外部边界、取最大连通区域、模板大小为  $2 \times 2$  的腐蚀以及模板大小为  $10 \times 10$  的闭操作后, 再通过空洞进行填充, 得到完整的肺部区域掩码, 最后将肺实质掩码与原图像相乘, 得到最终分割的肺实质图像, 分别如图 1(B)~(H) 所示。




图 1 肺部 CT 图像的预处理

Fig. 1 Preprocessing of lung CT images

预处理中窗宽和窗位的选取是为了便于掩码生成以及展示效果, 在实际应用中, 掩码会作用于原始的 CT 数据, 原始数据的动态范围并未被压缩, 因此需要对原始数据进行归一化操作以加快网络训练的收敛. 对于肺部 CT, CT 值大于 600 HU 则说明不是肺部组织, 由于本文不需考虑骨组织, 因此选取归一化阈值为  $[-1\ 200, 600]$ , 将该范围归一化到  $[0, 255]$  区间. 本文采用的归一化公式如下:

$$\text{pixel}_{\text{normal}} = \frac{\text{pixel}_{\text{CT}} - (-1\ 200)}{600 - (-1\ 200)}, \quad (1)$$

其中:  $\text{pixel}_{\text{CT}}$  表示肺部图像的 CT 值;  $\text{pixel}_{\text{normal}}$  表示归一化后的值.

经过上述处理后, 原始数据中只保留了肺部数据. 为充分利用 CT 数据中的三维信息, 网络模型采用三维卷积结构, 因此需将数据也处理成三维形式. 由于数据集中含有的 CT 图像是由不同仪器设备采集的, 其原始空间坐标系与像素间隔并不完全一致, 因此必须统一坐标系统. 本文首先将原始数据所采用的世界坐标系转换为统一的图像坐标系, 并通过平移变换将原点的位置统一. 然后利用尺度变换和三次样条插值将像素间隔统一为每个像素表示世界坐标系中的  $1\text{ mm} \times 1\text{ mm}$  大小. 最后, 为提高训练时的读取效率, 将所有训练数据都预先裁剪为  $96 \times 96 \times 96$  的三维数据块并进行磁盘缓存, 裁剪步长为 4, 延拓时采用水对应的 CT 值 170 HU 进行填充.

### 3.2 模型

本文使用的模型分为检测器和分类器两部分. 检测器以 U-Net 为基础结构, 编码阶段采用 14 层三维卷积, 将尺寸为  $[N, 1, 96, 96, 96]$  的输入编码为尺寸  $[N, 512, 3, 3, 3]$  的特征 (尺寸含义为  $[\text{batch size}, \text{channels}, W, H, D]$ , 其中 batch size 和  $N$  表示数据中含有的图片数量, channels 为通道数,  $W, H, D$  分别表示输入数据在  $x, y, z$  方向上的尺寸). 解码阶段采用相同深度的三维反卷积层, 每隔两层编码器将编码特征与解码特征进行连接, 最后得到  $[N, 15, 96, 96, 96]$  的输出特征, 其中包含  $[96, 96, 96]$  的语义信息和对应三种 anchor (尺度为 5, 10, 20) 的四个偏移量 (分别为坐标  $x, y, z$  的偏移量和直径  $d$ ) 以及置信度  $p$ .

对检测器的输出进行多尺度处理. 首先, 将检测到的所有置信度大于 80% 的候选结节按检测器预测出的中心坐标和直径从原始数据中进行裁剪; 然后将裁剪所得数据块与检测器给出的语义信息中心

重合,以语义信息为掩码,作用于原始数据,将候选结节外的像素屏蔽,起到突出候选结节并减少外部干扰的作用;最后将处理后的候选结节输入到一个五级的池化金字塔,如图 2 所示,池化尺度分别为 1,3,4,6,8,无论输入尺寸多大,最终输出的特征都是 126 维( $126=1^2+3^2+4^2+6^2+8^2$ ),该特征将作为分类器的输入。




图 2 金字塔池化

Fig. 2 Pyramid pooling

分类器接受池化金字塔的输出,并最终给出该候选结节是恶性结节的概率. 分类器网络的构造单元为双路径网络(dual path network, DPN)<sup>[26]</sup>,它将输入特征分为两部分,分别通过密集链接块和残差块,在输出端重新拼合成一个特征向量. 残差结构能将特征传递到更深的结构,便于通过加深网络层次获取更好的效果,而密集连接结构能有效防止由于网络加深而导致的梯度消失问题,DPN 能将两种结构相结合. 由于分类器要处理的特征向量较大,DPN 使得模型能使用更多的层以更平缓的方式进行特征收缩,相比于更激进、更快速的收缩,本文采用的方式有效减少了特征的损失. 同时,由于残差结构的加入,模型的可训练参数被控制在合理范围内,对加速训练过程和防止过拟合也有一定的意义. 图 3 为网络结构,图中矩形高度和宽度的变化分别表示特征张量的尺寸和通道数. 在 4 个 DPN 层中分别使用了 3 层、4 层、20 层和 3 层的 DPN 块,最后通过最大池化层和全连接线性层输出二分类结果.




图 3 网络结构

Fig. 3 Network structure

### 3.3 损失函数

由于本文采用两阶段的模型方案,因此损失函数由两部分组成:回归损失和分类损失. 其中回归损失用于训练检测器,而分类损失用于训练分类器.

定义 $(\tilde{x}, \tilde{y}, \tilde{z}, \tilde{d})$ 为检测器预测得到的结节在原始空间中的坐标和尺寸, $(x, y, z, d)$ 为真实结节在原始空间中的坐标和尺寸, $(x_a, y_a, z_a, d_a)$ 为对应 anchor 的坐标和尺寸. 相对位置和尺寸的预测值和真实值分别为 $\tilde{p}$ 和 $p$ ,则有

$$\tilde{p} = \left( \frac{\tilde{x} - x_a}{d_a}, \frac{\tilde{y} - y_a}{d_a}, \frac{\tilde{z} - z_a}{d_a}, \log \frac{\tilde{d}}{d_a} \right),$$

$$p = \left( \frac{x - x_a}{d_a}, \frac{y - y_a}{d_a}, \frac{z - z_a}{d_a}, \log \frac{d}{d_a} \right). \quad (2)$$

定义函数  $\varphi(p, \tilde{p})$ , 当 anchor 与 ground truth(真实值)边界框的交集与并集的面积比值(intersection over union, IoU)大于 0.5 时,  $\varphi(p, \tilde{p}) = 1$ ; 否则  $\varphi(p, \tilde{p}) = 0$ . 对  $\tilde{p}$  和  $p$  应用  $l_1$  平滑的回归损失函数<sup>[27]</sup>, 得到检测器的回归损失为

$$L_{\text{reg}} = \varphi(p, \tilde{p}) \times \text{smooth}_{l_1}(p - \tilde{p}), \quad (3)$$

其中  $\text{smooth}_{l_1}$  函数定义为

$$\text{smooth}_{l_1}(x) = \begin{cases} 0.5x^2, & |x| < 1, \\ |x| - 0.5, & \text{其他}. \end{cases} \quad (4)$$

对于分类损失, 本文使用二元交叉熵损失函数( $\text{CrossEntropy}_{\text{binary}}$ ). 定义分类器预测值和真实值的分类值分别为  $\tilde{c}$  和  $c$ , 则分类损失为

$$L_{\text{cls}} = \text{CrossEntropy}_{\text{binary}}(\tilde{c}, c) = - \sum_{i=0}^1 \tilde{c}_i \log(c_i) + (1 - \tilde{c}_i) \log(1 - \tilde{c}_i). \quad (5)$$

在回归损失和分类损失的基础上将总损失定义为

$$L_{\text{total}} = \alpha L_{\text{cls}} + L_{\text{reg}}, \quad (6)$$

其中  $\alpha$  为权重系数, 在实验中取  $\alpha = 0.5$ .

### 3.4 算法流程

用于肺结节检测和分类的两阶段深度学习方法的算法流程如图 4 所示. 数据集经过预处理后, 构成(数据, 标签)的形式. 其中, 数据为边长 512 像素的立方体数据, 标签中标识有结节的位置、尺寸和良恶性. 训练阶段, 通过随机采样获取边长为 96 像素的立方体作为训练样本, 在测试阶段, 通过步长为 4 的密集采样获取相同尺寸的样本. 检测网络能根据输入的样本给出其中候选结节的位置、置信度和语义信息. 在训练阶段, 检测网络的输出用于参与回归损失的计算, 分类网络的输入通过标签中的位置和尺寸信息完成采样, 而在测试阶段, 使用检测网络输出的候选结节位置进行采样, 并使用语义信息进行掩码处理, 以便充分利用原始数据的特征信息. 最后, 经过空间金字塔池化, 统一维度的特征信息被输入到分类网络, 得到良恶性的分类结果.

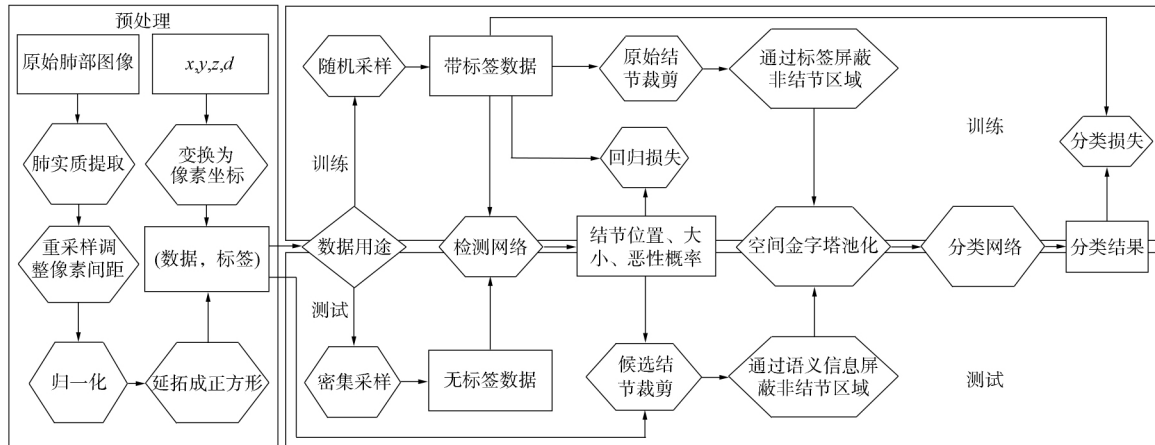


图 4 训练和测试阶段的算法流程

Fig. 4 Algorithm flow of training and testing phase

## 4 实验

本文采用 LUNA16 数据集进行训练和测试. LUNA16 共有 888 个 CT 序列, 实际上是一个更大的数据集 LIDC-IDRI 的子集, 本文在训练和测试中使用 LUNA16 数据集的 CT 数据和标签以及对应的 LIDC-IDRI 标签. 888 张 CT 中, 共有 36 378 个结节被标出, 在 LUNA16 数据集中, 只有直径  $> 3$  mm 的结节作为样本, 直径  $< 3$  mm 的结节和非结节都不选入, 而直径  $< 3$  mm 的结节有 11 509 个, 非结节

区域有 19 004 个, 剩余 5 765 个. 此外, 若两个结节的中心距离小于半径之和, 则对这两个结节进行合并, 合并的中心和半径是两个结节的均值. 经过上述处理, 剩余 2 290 个结节. 结节的恶性程度标注来自 4 位专家, 对于每个结节, 给出标注的专家可能是 1~4 个, 标注的方式是给出一个[1,5]的整数表示恶性程度, 本文对该值取平均值, 排除所有等于 3 mm 的情况, 小于 3 mm 的认为是良性结节, 大于 3 mm 的认为是恶性结节. 最终有 1 186 个结节进入训练集.

将筛选得到的数据通过沿 3 个轴反转和随机选取  $4 \times 4 \times 4$  大小的区域填充为水的 CT 值 170 HU 的方式进行数据扩充. 采用随机梯度下降进行训练, 动量参数设置为 0.9, batch size=16, 学习率初始化为 0.1, 每经过 70 个 epoch(使用所有数据训练一次称为一个 epoch)将学习率调整为原来的 1/10, 网络在训练 200 个 epoch 时收敛.

为衡量检测器的性能, 将本文的检测器与 3D DPN-26 Faster R-CNN 和 3D Res-18 Faster R-CNN<sup>[16]</sup> 检测器进行对比实验. 对比指标采用 LUNA16 数据集的官方评价标准, 即无限接收特性曲线(free-response receiver operating characteristic curves, FROC). 图 5 为假阳性率为 0.125, 0.25, 0.5, 1, 4, 8 时的灵敏度. 由图 5 可见, 本文检测器的性能优于作为比较基线的检测器, 并且本文检测器具有更少的可训练参数(3D DPN-26 Faster R-CNN 检测器有超过  $9 \times 10^7$  的可训练参数, 而本文检测器只有不到  $2 \times 10^6$  的可训练参数), 能更快地训练.

表 1 列出了不同网络模型对 LUNA16 中结节的分类结果. 由表 1 可见: 由于充分利用了 CT 的三维信息, 3D 结构的模型要优于 2D 结构的模型, 使用 3D DPN 对结节图像进行分类取得了比多尺度 CNN(卷积神经网络)<sup>[25]</sup>, 2D CNN, 3D CNN 以及更高的分类准确率; 本文提出的模型中使用空间金字塔池化对不同尺度的候选结节进行尺度统一, 并利用检测器的输出对分类器的输入进行处理, 且由于 DPN 的特性, 本文分类器能以更合理的速度进行维度收缩, 从而提升了分类的效果.

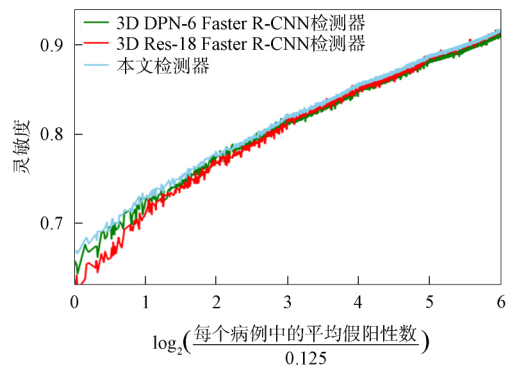


图 5 灵敏度曲线  
Fig. 5 Curves of sensitivity

表 1 不同网络模型对 LUNA16 上的结节分类准确率

Table 1 Accuracy of nodule classification on LUNA16 by different models

网络模型	准确率/%	网络模型	准确率/%
Multi-scale CNN <sup>[28]</sup>	86.84	Vanilla 3D CNN <sup>[29]</sup>	87.40
Slice-level 2D CNN <sup>[29]</sup>	86.70	DeepLung <sup>[16]</sup>	90.44
Nodule-level 2D CNN <sup>[29]</sup>	87.30	本文	91.04

本文还与 LIDC-IDRI 数据集中 4 名医生的标注结果进行了对比, 选取所有被 4 名医生标注的测试数据. 对于一个样本, 4 名医生会对其恶性程度给出 1~5 的评分, 本文对 4 名医生的评分进行平均, 将平均结果作为真实值, 剔除平均结果为 3 的样本, 平均值在 3 以上的视为恶性, 否则视为良性. 如果一个医生给出的良恶性结果与真实值不符, 则认为这名医生对该样本给出了错误标注. 根据以上原则, 统计出 4 名医生在测试集上的分类准确率, 并进行对比实验, 对比结果列于表 2.

表 2 分类准确率(%)对比

Table 2 Comparison of classification accuracy (%)

方法	医生 1	医生 2	医生 3	医生 4	平均
医生标注法	93.44	93.69	91.82	86.03	91.25
文献[12]算法	93.55	93.30	93.19	90.89	92.74
本文算法	93.62	93.45	93.53	90.75	92.83

本文的分类器输出二分类结果, 对于良性和恶性, 分别给出分类概率, 采用大于 50% 的类别作为最终分类结果. 表 3 列出了预测概率占总体数据的比例. 由表 3 可见, 63.92% 的样本能给出接近 0 或

1 的分类结果, 表明模型受到了有效的训练, 分类效果明确.

表 3    预测概率占总体数据的比例

Table 3    Proportion of prediction probability in total data

概率	>0.9 或<0.1	>0.8 或<0.2	>0.7 或<0.3	>0.6 或<0.4
占比/%	63.92	80.03	88.92	94.36

综上所述, 本文提出了一种用于肺部 CT 图像中肺结节检测和分类的深度学习模型, 使用两阶段方法, 先使用基于 U-Net 的三维卷积网络进行结节的检测, 得到候选结节的语义信息和位置信息, 再根据检测结果对原始数据进行处理, 使用空间金字塔池化进行多尺度操作, 然后使用基于 DPN 的分类器进行分类, 最后给出良恶性分类结果. 在 LUNA16 数据集上对肺结节检测和分类模型进行测试的结果表明, 本文方法准确度较高.

参 考 文 献

[ 1 ] GOULD M K, FLETCHER J, IANNETTONI M D, et al. Evaluation of Patients with Pulmonary Nodules: When Is It Lung Cancer?: ACCP Evidence-Based Clinical Practice Guidelines [J]. Chest, 2007, 132(3): 108S-130S.

[ 2 ] HE K M, GKIOXARI G, DOLLÁR P, et al. Mask R-CNN [C]//Proceedings of the IEEE International Conference on Computer Vision. Piscataway, NJ: IEEE, 2017: 2961-2969.

[ 3 ] LIU C, KIM K, GU J W, et al. PlaneRCNN: 3D Plane Detection and Reconstruction from a Single Image [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE, 2019: 4450-4459.

[ 4 ] WANG X L, GIRSHICK R, GUPTA A, et al. Non-local Neural Networks [C]//Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE, 2018: 7794-7803.

[ 5 ] 胡思才, 孙界平, 琚生根, 等. 基于深度神经网络和概率矩阵分解的混合推荐算法 [J]. 四川大学学报(自然科学版), 2019, 56(6): 1033-1041. (HU S C, SUN J P, JU S G, et al. Hybrid Recommendation Algorithm Based on Deep Neural Network and Probabilistic Matrix Factorization [J]. Journal of Sichuan University (Natural Science Edition), 2019, 56(6): 1033-1041.)

[ 6 ] 方阳, 刘英杰, 孙立博, 等. 基于 SSD 模型的人脸检测与头部姿态估计融合算法 [J]. 江苏大学学报(自然科学版), 2019, 40(4): 451-457. (FANG Y, LIU Y J, SUN L B, et al. Fusion Algorithm of Face Detection and Head Pose Estimation Based on SSD Model [J]. Journal of Jiangsu University (Natural Science Edition), 2019, 40(4): 451-457.)

[ 7 ] 魏超, 范自柱, 张泓, 等. 基于深度学习的农作物病害检测 [J]. 江苏大学学报(自然科学版), 2019, 40(2): 190-196. (WEI C, FAN Z Z, ZHANG H, et al. Crop Disease Detection Based on Deep Learning [J]. Journal of Jiangsu University (Natural Science Edition), 2019, 40(2): 190-196.)

[ 8 ] SHEN C Y, GONZALEZ Y, CHEN L Y, et al. Intelligent Parameter Tuning in Optimization-Based Iterative CT Reconstruction via Deep Reinforcement Learning [J]. IEEE Transactions on Medical Imaging, 2018, 37(6): 1430-1439.

[ 9 ] LIAO F Z, LIANG M, LI Z, et al. Evaluate the Malignancy of Pulmonary Nodules Using the 3D Deep Leaky Noisy-or Network [J]. IEEE Transactions on Neural Networks and Learning Systems, 2019, 30(11): 3484-3495.

[10] 宋璐, 冯艳平, 卫亚博. 基于灰度 DAG 熵最大化量化分辨率医学图像增强 [J]. 四川大学学报(自然科学版), 2018, 55(2): 316-322. (SONG L, FENG Y P, WEI Y B. Gray Level DAG Maximum Entropy Based on Quantization Resolution for Medical Image Tone Enhancement [J]. Journal of Sichuan University (Natural Science Edition), 2018, 55(2): 316-322.)

[11] 凌语, 孙自强. 基于卷积神经网络的乳腺病理图像识别算法 [J]. 江苏大学学报(自然科学版), 2019, 40(5): 573-578. (LING Y, SUN Z Q. Recognition Algorithm of Breast Pathological Images Based on Convolutional Neural Network [J]. Journal of Jiangsu University (Natural Science Edition), 2019, 40(5): 573-578.)

- [12] ROTH H R, LU L, LIU J M, et al. Improving Computer-Aided Detection Using Convolutional Neural Networks and Random View Aggregation [J]. IEEE Transactions on Medical Imaging, 2016, 35(5): 1170-1181.
- [13] CIOMPI F, DE HOOP B, VAN RIEL S J, et al. Automatic Classification of Pulmonary Peri-Fissural Nodules in Computed Tomography Using an Ensemble of 2D Views and a Convolutional Neural Network Out-of-the-Box [J]. Medical Image Analysis, 2015, 26(1): 195-202.
- [14] KUMAR D, WONG A, CLAUSI D A. Lung Nodule Classification Using Deep Features in CT Images [C]// Proceedings of Conference on Computer and Robot Vision. Piscataway, NJ: IEEE, 2015: 133-138.
- [15] KIM B C, SUNG Y S, SUK H I. Deep Feature Learning for Pulmonary Nodule Classification in a Lung CT [C]// Proceedings of International Winter Conference on Brain-Computer Interface. Piscataway, NJ: IEEE, 2016: 1-3.
- [16] ZHU W T, LIU C C, FAN W, et al. DeepLung: Deep 3D Dual Path Nets for Automated Pulmonary Nodule Detection and Classification [C]// Proceedings of IEEE Winter Conference on Applications of Computer Vision. Piscataway, NJ: IEEE, 2018: 673-681.
- [17] HE K M, ZHANG X Y, REN S Q, et al. Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(9): 1904-1916.
- [18] SETIO A A A, TRAVERSO A, DE BEL T, et al. Validation, Comparison, and Combination of Algorithms for Automatic Detection of Pulmonary Nodules in Computed Tomography Images: The LUNA16 Challenge [J]. Medical Image Analysis, 2017, 42: 1-13.
- [19] REN S Q, HE K M, GIRSHICK R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149.
- [20] SIMONYAN K, ZISSERMAN A. Very Deep Convolutional Networks for Large-Scale Image Recognition [C]// Proceedings of International Conference on Learning Representations. [S.l.]: ICLR, 2015: 1-14.
- [21] HE K M, ZHANG X Y, REN S Q, et al. Deep Residual Learning for Image Recognition [C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE, 2016: 770-778.
- [22] FELZENSZWALB P F, HUTTENLOCHER D P. Efficient Graph-Based Image Segmentation [J]. International Journal of Computer Vision, 2004, 59(2): 167-181.
- [23] LONG J, SHELHAMER E, DARRELL T. Fully Convolutional Networks for Semantic Segmentation [C]// Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE, 2015: 3431-3440.
- [24] JÉGOU S, DROZDAL M, VAZQUEZ D, et al. The One Hundred Layers Tiramisu: Fully Convolutional DenseNets for Semantic Segmentation [C]// Proceedings of IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops. Piscataway, NJ: IEEE, 2017: 1175-1183.
- [25] RONNEBERGER O, FISCHER P, BROX T. U-Net: Convolutional Networks for Biomedical Image Segmentation [C]// Proceedings of International Conference on Medical Image Computing and Computer-Assisted Intervention. Berlin: Springer, 2015: 234-241.
- [26] CHEN Y P, LI J N, XIAO H X, et al. Dual Path Networks [C]// Proceedings of Advances in Neural Information Processing Systems. [S.l.]: NIPS, 2017: 4467-4475.
- [27] GIRSHICK R. Fast R-CNN [C]// Proceedings of the IEEE International Conference on Computer Vision. Piscataway, NJ: IEEE, 2015: 1440-1448.
- [28] SHEN W, ZHOU M, YANG F, et al. Multi-scale Convolutional Neural Networks for Lung Nodule Classification [C]// Proceedings of International Conference on Information Processing in Medical Imaging. Berlin: Springer, 2015: 588-599.
- [29] YAN X J, PANG J N, QI H, et al. Classification of Lung Nodule Malignancy Risk on Computed Tomography Images Using Convolutional Neural Network: A Comparison between 2D and 3D Strategies [C]// Proceedings of Asian Conference on Computer Vision. Berlin: Springer, 2016: 91-101.

(责任编辑: 韩 啸)